



## 근육의 활성화 시 상관관계를 반영한 Target Cascading 기반 머슬시너지 추출 기법

### Extracting Time-Varying Muscle Synergy Based on Target Cascading to Impose a Temporal Relationship in Muscle Activation as Constraints

김장현\*<sup>①</sup>, 윤한일\*\*†<sup>②</sup>

Janghyeon Kim and Han Ul Yoon†

\*연세대학교 미래캠퍼스 대학원 전산학과 석사과정, \*\*연세대학교 미래캠퍼스 소프트웨어학부 교수

\*M.S. Course, Department of Computer Science, Yonsei University(Mirae)

\*\*Professor, Division of Software, Yonsei University(Mirae)

#### 요약

머슬시너지는 중추신경계가 동작을 수행할 때, 근육에 전달되는 모듈화된 제어 신호이다. 일반적으로, 머슬시너지는 근전도 신호로부터 최적화 기반 알고리즘인 비부정 행렬 인수분해를 통해 추출할 수 있다. Time-varying 머슬시너지 추출의 경우 머슬시너지의 수, 근육의 수, 타임 스텝의 길이가 최적화 성능에 영향을 끼친다. 또한, 비현실적인 머슬시너지 추출을 방지하기 위해 생체역학적 제약조건을 부과한다면 최적화 수행 시간 및 복원율이 더욱 저하된다. 따라서 본 논문에서는 target cascading을 적용하여 위 문제를 해결하는 방법론을 제안한다. Target cascading은 하나의 프로세스를 메인/서브 시스템으로 나누어 최적화를 수행하므로 빠르게 최적해를 구한다. 단일 머슬시너지는 독립된 하나의 서브 시스템으로 간주할 수 있으므로, 머슬시너지를 서브 시스템으로 설정하여 target cascading을 진행하면 최적화 성능의 향상을 기대할 수 있다. Target cascading을 적용했을 때와 적용하지 않았을 때 추출하는 각각의 머슬시너지를 최적화 소요 시간 및 복원율을 관점에서 비교 분석한다. 그 결과, 생체역학적 제약조건이 부과된 time-varying 머슬시너지 추출에 제안한 방법론을 적용했을 때 평균적으로 3배 빠른 속도로 최적화하며, 복원율도 평균적으로 약 1.6배 높았다.

**키워드 :** Target Cascading, Time-varying 머슬시너지, 머슬시너지 최적화, 생체역학적 제약 조건, 비부정 행렬 인수분해

#### Abstract

Muscle synergy is a modularized control signal transmitted by the central neural system to control muscles when we perform specific tasks. After measuring surface electromyography, generally, muscle synergy is used to be extracted by employing the non-negative matrix factorization which is an optimization-based algorithm. When we extract time-varying muscle synergy, the number of synergies, the number of muscles involved in a synergy, and the length of time step are crucial hyper parameters which have an effect on optimization performance. Moreover, the aforementioned optimization performance might be severely deteriorated when biomechanical constraints are imposed to avoid extracting unrealistic muscle synergy. In this paper, we propose a method in which a target cascading plays a key role to solve the issues above. Under the target cascading, the entire process is divided into main-/sub-system and each process is then optimized individually, which in turn, accelerates the optimization process. A single muscle synergy conceptually corresponds to an independent sub-system; accordingly, we can expect better performance by adopting the target cascading for the muscle synergy extraction process. In the experiment, we extract time-varying muscle synergies under two conditions - to whether a target cascading is applied or not - and compare the outcomes in perspectives of an elapsed time as well as a reconstruction ratio. The results show, for the given constrained time-varying muscle synergy extraction problem, that the optimization process can be improved by 3 times and 1.6 times in terms of an elapsed time and as a reconstruction ratio, respectively, when the target cascading is applied.

**Key Words :** Target Cascading, Time-varying Muscle Synergy, Muscle Synergy Optimization, Biomechanical Constraints Non-negative Matrix Factorization

Received: Mar. 01, 2022

Revised : Apr. 08, 2022

Accepted: Apr. 14, 2022

† Corresponding author  
(huyoon@yonsei.ac.kr)

본 논문은 본 학회 2021년도 추계학술대회  
에서 선정한 우수 논문입니다.

This is an Open-Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License (<http://creativecommons.org/licenses/by-nc/3.0>) which permits unrestricted noncommercial use, distribution, and reproduction in any medium, provided the original work is properly cited.

## 1. 서 론

Bernstein에 의해 존재가 밝혀진 머슬시너지는 중추신경계가 사람의 움직임을 제어할 때 사용하는 기본적인 근육 그룹이다[1]. 중추신경계는 개별 근육에 신호를 전달하지 않고 머슬시너지에 신호를 전달하여 모듈화된 방식으로 신체를 제어한다. 특정 작업 수행에 고유하게 사용되는 머슬시너지를 task-specific muscle synergy라고 하며, 여러 작업에서 공통으로 사용되는 머슬시너지는 shared muscle synergy라 부른다[2].

머슬시너지는 surface electromyography(sEMG)를 비부정 행렬 인수분해하여 추출한다. d'Avella와 Lacquaniti는 팔 운동에서 sEMG를 획득하고 비부정 행렬 인수분해를 사용하여 머슬시너지를 추출하였다[3]. 또한, Chvatal과 Ting은 보행 시 사람의 다리 근육에서 사용되는 머슬시너지를 추출하였다[4]. 비부정 행렬 인수분해는 선형 최적화 기반 알고리즘이다. 따라서, 이로부터 추출된 해인 머슬시너지는 선형 조합의 특성을 만족하면 되므로, 때때로 실제 동작을 설명하기 힘든 근육 구성을 가질 수 있다. 이러한 문제를 해결하기 위해서는 머슬시너지를 추출하는 과정에 적절한 제약조건이 추가되어야 한다.

Target cascading(TC)은 하나의 큰 시스템을 메인/서브 시스템으로 나누고 각 시스템에서 최적화를 진행하여 큰 시스템을 최적화하는 기법이다[5]. Kim et al.은 TC를 제안하고 자동차 서스펜션의 파라미터 최적화 문제에 적용하였다[6]. Allison et al.은 TC를 사용하여 비행기 디자인 문제에 적용하는 방법을 제안하였다[7]. Time-varying 머슬시너지의 경우 시너지의 수, 근육의 수, 타임 스텝의 길이에 따라 최적화해야 하는 변수가 늘어나고 제약조건을 추가하게 되면 최적화에 걸리는 시간이 길어진다. 머슬시너지는 운동에 대한 독립적인 모듈이므로, 서브 시스템으로 생각할 수 있다. 이러한 사실을 TC를 적용한다면 위의 선행 연구에서 보인 것과 같은 효과를 기대할 수 있다.

위와 같은 이유로 본 논문은 생체역학적 제약조건 반영을 위한 TC 기반 머슬시너지 추출 기법을 제안한다. 제안하는 방법론을 요약하면 다음과 같다. 먼저 sEMG로부터 생체역학적 제약조건을 추출하고, 추출된 제약조건을 time-varying 머슬시너지 최적화에 추가한다. 이어서, 하나의 큰 머슬시너지 최적화 프로세스를 각 머슬시너지를 기준으로 메인/서브 시스템으로 나눈다. 나누어진 메인/서브 시스템에 TC를 적용하여 time-varying 머슬시너지 최적화를 진행한다.

논문의 구성은 다음과 같다. 2장에서는 time-varying 머슬시너지와 생체역학적 제약조건으로 사용되는 근육 관계 매트릭스의 수학적 정의와 추

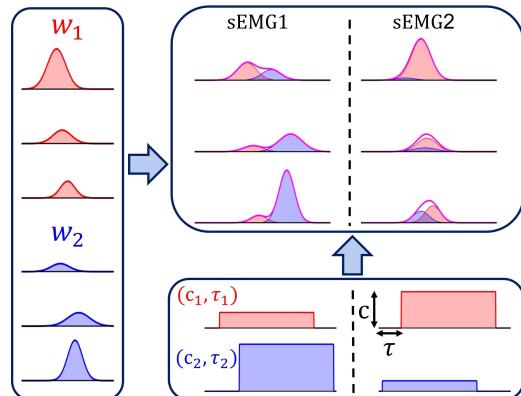


그림 1. Time-varying 머슬시너지( $d=3$ ,  $n=2$ 일 때의 예)  
Fig. 1. An example of time-varying muscle synergies with  $d=3$ ,  $n=2$

출 방법에 대하여 논한다. 그리고 제약조건을 반영한 머슬시너지 최적화 문제를 TC 기반 최적화 문제로 정의한다. 3장에서는 데이터의 수집과 전처리를 설명하고, 결과 비교를 위해 TC를 적용하지 않은 머슬시너지와 TC를 적용한 머슬시너지 추출을 진행한다. 4장에서는 두 가지 조건 아래에서 추출된 머슬시너지의 결과를 비교, 분석하여 제안된 방법론의 효과를 확인한다. 마지막으로 5장에서는 결론과 향후 연구에 대하여 논한다.

## 2. 생체역학적 제약조건 및 Target Cascading 기반 머슬시너지 추출 기법

### 2.1 Time-varying 머슬시너지 정의

$d$ 개의 채널,  $k$ 개의 타임 스텝을 가지는 sEMG를  $\mathbf{M} \in \mathbb{R}^{d \times k}$ 로 나타낸다고 하자. Time-varying 머슬시너지의 타임 스텝의 길이가  $l$ 일 때, time-varying 머슬시너지는 매트릭스  $\mathbf{w}_i \in \mathbb{R}^{d \times l}$ 로 표현한다. 활성화 계수는  $c_i \in \mathbb{R}^+$ 로 표현하고, 지연시간은  $\tau_i \in \mathbb{R}^+$ 로 표현한다. Time-varying 머슬시너지의 개수가  $n$ 개 있을 때, 시계열 sEMG 데이터  $\mathbf{M}$  행렬의 각 엔트리는 식 (1)과 같이 표현할 수 있다.

$$\mathbf{M}(d,k) = \sum_{i=1}^n c_i \mathbf{w}_i(d, k - \tau_i) \quad (1)$$

그림 1은 근육의 개수가 3개, 머슬시너지의 개수가 2개일 때의 예시이다.  $\mathbf{w}_1$ 와  $\mathbf{w}_2$ 가 주어졌을 때,  $c_i$ 와  $\tau_i$ 가 달라짐에 따라 만들어지는 sEMG가 다른 것을 확인할 수 있다.  $\mathbf{w}_i$ 와  $c_i$ 는  $\mathbf{M}$ 을 비부정 행렬 인수분해하여 추출하고,  $\tau_i$ 는  $\mathbf{w}_i$ 와  $\mathbf{M}$ 의 cross-correlation을 사용하여 선택한다.

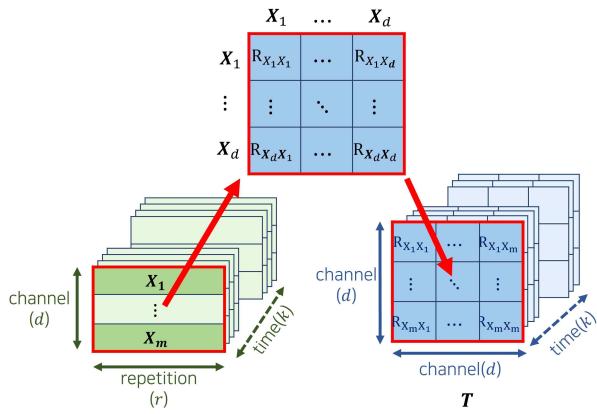


그림 2. 행렬  $\mathbf{X}$ 로부터  $R_{\mathbf{X}_1, \mathbf{X}_2}$ 를 계산하여 상관관계 텐서형 데이터  $\mathbf{T}$ 를 만드는 과정

Fig. 2. A procedure to produce a relationship-based tensor-type data  $\mathbf{T}$  by calculating an  $R_{\mathbf{X}_1, \mathbf{X}_2}$  with a matrix  $X$

## 2.2 균육 관계 매트릭스 정의

근육 관계 매트릭스는  $\hat{\mathbf{S}}_i \in \mathbb{R}^{d \times d}$ 로 표현하며, 행과 열은 채널을 뜻하고 행과 열이 교차하는 지점은 두 균육 간 상관관계를 나타낸다. 벡터  $\mathbf{a}_i \in \mathbb{R}^{1 \times k}$ 는 타임 스텝  $k$ 에서 상용하는 균육 관계 매트릭스가 활성화된 정도를 나타내는 활성화 커브다. 운동을 반복한 횟수를  $r$ 이라고 하자. 그림 2는 균육 관계 매트릭스를 추출하기 위한 텐서형 데이터  $\mathbf{T} \in \mathbb{R}^{d \times d \times k}$ 의 제작 과정을 보여준다.  $r$ 개의  $\mathbf{M}$ 을 그림 2 왼쪽 아래와 같은 3차원 텐서형 데이터로 구성한다. 이어서 채널(channel)과 반복 차수(repetition)를 차원으로 하는 2차원 행렬  $\mathbf{X} \in \mathbb{R}^{d \times r}$ 에 식 (2)를 적용하여 균육 간 상관관계를 계산한다.

$$R_{\mathbf{X}_1, \mathbf{X}_2} = \text{MAX}\left(0, \frac{\text{cov}(\mathbf{X}_1, \mathbf{X}_2)}{\sigma_{\mathbf{X}_1} \sigma_{\mathbf{X}_2}}\right) \quad (2)$$

식 (2)에서  $\text{cov}(\mathbf{X}_1, \mathbf{X}_2)$ 는 시계열 데이터  $\mathbf{X}_1, \mathbf{X}_2$ 의 공분산을 의미하며,  $\sigma_{\mathbf{X}_1}, \sigma_{\mathbf{X}_2}$ 는 각각  $\mathbf{X}_1, \mathbf{X}_2$ 의 표준 편차를 의미한다. 전체 시간(time) 차원에 대하여 균육 간 상관관계를 계산하여 그림 2 오른쪽 아래와 같은 텐서형 데이터  $\mathbf{T}$ 를 만든다.  $\mathbf{S}_i$ 의 개수는 머슬시너지의 개수와 같아야 하며,  $\mathbf{S}_i$ 의 개수가  $n$  개 있을 때  $\mathbf{T}$ 의 각 엔트리는 식 (3)과 같이 표현할 수 있다.

$$\mathbf{T}(d, d, k) = \sum_{i=1}^n \mathbf{S}_i(d, d) \mathbf{a}_i(k) \quad (3)$$

$\mathbf{S}_i, \mathbf{a}_i$ 는  $\mathbf{T}$ 를 비부정 행렬 인수분해하여 추출한다.

## 2.3 Target Cascading 기반 머슬시너지 최적화

머슬시너지  $\mathbf{w}_i$ 를 사용하여 만들어진 균육 관계 매트릭스를  $\hat{\mathbf{S}}_i$ 라고 하자.  $\mathbf{S}_i$ 는 동작에서 사용되는 균육 간의 관계이므로 머슬시너지로 만들어진  $\hat{\mathbf{S}}_i$ 도 이 관계를 만족해야 한다. 이 관계를 제약조건으로 반영하여 최적화 수식을 식 (4)와 같이 표현한다.

$$\begin{aligned} & \min_{\hat{\mathbf{w}}_i, \hat{c}_i, \hat{\tau}_i} \sum_d \sum_k (\mathbf{M}(d, k) - \hat{\mathbf{M}}(d, k))^2 \\ \text{sub to. } & \hat{\mathbf{M}}(d, k) = \sum_{i=1}^n \hat{c}_i \hat{\mathbf{w}}_i(d, k - \hat{\tau}_i) \\ & \sum_d \sum_d |\mathbf{S}_i(d, d) - \hat{\mathbf{S}}_i(d, d)| < \epsilon, \quad i = 1, \dots, n \end{aligned} \quad (4)$$

식 (4)의 최적화는  $n$ 개의 머슬시너지  $\hat{\mathbf{w}}_i$ 와 상응하는  $\hat{c}_i$ 를 모두 만족시키는 해를 찾는다. 그런데, 식 (4)는 제약조건이 있는 최적화 문제(Constrained optimization problem)이므로,  $\hat{\mathbf{w}}_i$ 의 차원과 개수  $n$ 에 따라 수행 시간이 증가하게 된다. 따라서, 위 문제를 해결하기 위해 TC를 적용하여 하나의 최적화 프로세스 내에서의 변수의 개수를 줄여준다.

머슬시너지는 하나의 독립된 모듈이므로 하나의 서브 시스템으로 생각할 수 있다. 그러므로, 메인 시스템은  $\mathbf{S}_i$ 를 제약조건으로 사용하지 않은 상태에서 머슬시너지를 최적화하고, 서브 시스템은  $\mathbf{S}_i$ 를 제약조건으로 사용하여 하나의 머슬시너지만 최적화한다. 메인 시스템과 서브 시스템에서 최적화의 결과로 추출되는 머슬시너지는 각각  $\hat{\mathbf{w}}_i^U, \hat{\mathbf{w}}_i^L$ 라 할 때, 메인 시스템의 최적화 문제는 식 (5)와 같이 쓸 수 있다.

$$\begin{aligned} & \min_{\hat{\mathbf{w}}_i^U, \hat{c}_i, \hat{\tau}_i, \epsilon_i} \sum_d \sum_k (\mathbf{M}(d, k) - \hat{\mathbf{M}}(d, k))^2 + \alpha \sum_{i=1}^n \epsilon_i \\ \text{sub to. } & \hat{\mathbf{M}}(d, k) = \sum_{i=1}^n \hat{c}_i \hat{\mathbf{w}}_i^U(d, k - \hat{\tau}_i) \\ & |\hat{\mathbf{w}}_i^U - \hat{\mathbf{w}}_i^L| < \epsilon_i \end{aligned} \quad (5)$$

위 식 (5)에서  $\hat{\mathbf{w}}_i^U$ 는 서브 시스템에서 최적화되는  $\hat{\mathbf{w}}_i^L$ 와의 차이가 작아지도록 제약조건이 설정된다.  $\epsilon_i$ 는 TC의 포뮬레이션에 의해 생기는 메인 시스템과 서브 시스템 차이를 나타내는 sensitivity 파라미터이며, 스케일러  $\alpha$ 에 의해 이 차이가 폐널티 함수로 이 최적화 문제에서 작동하도록 설정해 준다. 각 서브 시스템에서의 최적화 문제는 식 (6)과 같이 쓸 수 있다.

$$\begin{aligned} & \min_{\hat{\mathbf{w}}_i^L} |\hat{\mathbf{w}}_i^L - \hat{\mathbf{w}}_i^U| \\ \text{sub to. } & \sum_d \sum_d |\mathbf{S}_i(d, d) - \hat{\mathbf{S}}_i(d, d)| < \epsilon \end{aligned} \quad (6)$$

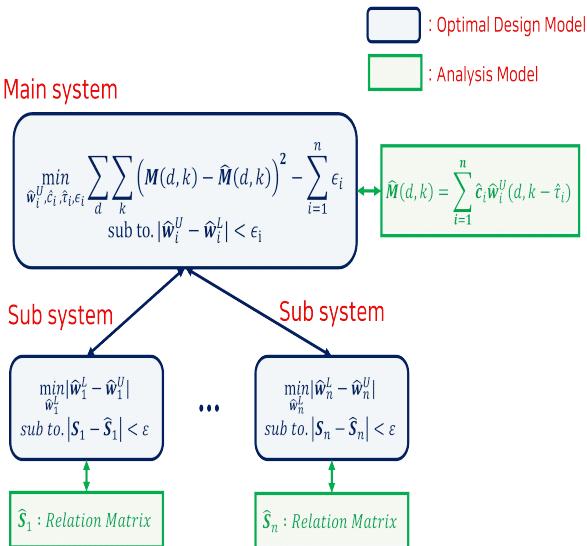


그림 3. Constrained time-varying 머슬시너지를 추출하기 위한 TC 기반 최적화 구조

Fig. 3. TC-based optimization architecture to extract constrained time-varying muscle synergy

위 식 (6)에서  $\hat{w}_i^L$  최적화에서는  $\mathbf{s}_i$ 와  $\hat{\mathbf{s}}_i$ 의 차이 값이 작아지도록 제약조건이 설정되었다. 서브 시스템을 통하여  $\hat{w}_i^U$ 는  $\mathbf{s}_i$ 를 만족시키는 머슬시너지로 최적화된다.

그림 3은 위의 식 (5)와 식 (6)으로 나타내진 TC 기반 최적화 프로세스를 도식화하여 보여준다. 먼저 메인 시스템에서 최적화를 진행하고  $\hat{w}_i^U$ 를 서브 시스템으로 전달한다. 다음으로 메인 시스템에서 전달받은  $\hat{w}_i^U$ 를 기반으로, 서브 시스템에서  $\hat{w}_i^L$ 을 최적화한다. 모든 서브 시스템의 최적화가 끝나면  $\hat{w}_i^L$ 를 메인 시스템으로 전달하고 다시  $\hat{w}_i^U$ 를 최적화한다. 위 과정을 반복하여 최종적으로  $\mathbf{s}_i$ 가 반영된  $\hat{w}_i^U$ 를 얻는다.

### 3. 실험 및 시너지 추출

#### 3.1 데이터 및 전처리

본 논문에서는 Camargo et al.가 연구결과 발표와 함께 공개한 보행 운동 데이터 중 평지에서의 정상 속도 보행 데이터를 사용하였다[8]. 데이터는 11채널 근전도 센서(Biometrics, Ltd. Newport, UK)로 부터 측정되었으며, 각 근육의 위치는 SENIAM (surface EMG for non-invasive assessment of muscles) 프로젝트에서 명시되어 있다[9]. 샘플링 레이트를 1000Hz로 설정하였으며, 밴드 패스의 구간을 20Hz~400Hz로 설정하여 적용하였다. 본 논문에서는 방법론에 대한 검증을 위해 한쪽 다리의 데이터로부터 time shift 하는 방식으로 생성하였다. 실제 gait cycle의 근전도 데이터는 오른쪽 다리와 왼쪽 다리의 근전도 데이터가 양쪽 발의 heel strike 시간 차이만큼 time shift 되어 나타나는 것처럼 보인다. 이러한 직관을 바탕으로, 오른쪽 다리의 근전도 데이터로부터 왼쪽 다리의 근전도 데이터를 생성하여 사용하였다[10]. 이는 이상치(ideal value)에 가까운 gait symmetry index를 가진 다른 쪽 다리의 데이터를 생성하기 위함이다 [11]. 복원된 22채널 데이터에서 양발의 medialis gastrocnemius(MGAS), tibialis anterior (TA), rectus femoris (RF), semitendinosus(ST), gluteus medius(GMED) 근육 채널들만 선택하여 10채널 데이터로 제작하였다. Toe off를 운동의 주기로 하여 총 45 반복 차수(repetition) 데이터를 획득하였다. 데이터 전처리는 윈도우 사이즈를 80으로 이동평균 필터링을 하였으며, 타임 스텝이 60이 되도록 적분하였다. 마지막으로 inter-channel normalization을 진행하여 최종적으로 획득한 데이터는 45개의  $\mathbf{M} \in \mathbb{R}^{10 \times 60}$ 를 얻었다. 그림 4는 보행에 사용되는 주요 다리 근육들의 시간에 따른 활성도를 보여주는 그림이다. 가로축은 타임 스텝을 나타내며, 세

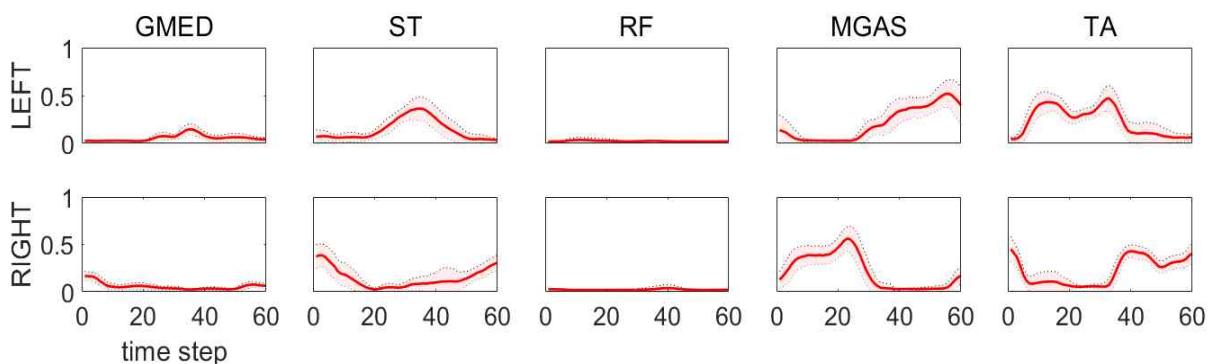


그림 4. 보행에 사용되는 주요 다리 근육들의 활성도 그래프(평균:빨강/굵은선, 표준편차:검정/점선)

Fig. 4. The activation graphs of major low-limb muscles during gait(mean:red/solid line, standard derivation:black/dotted line)

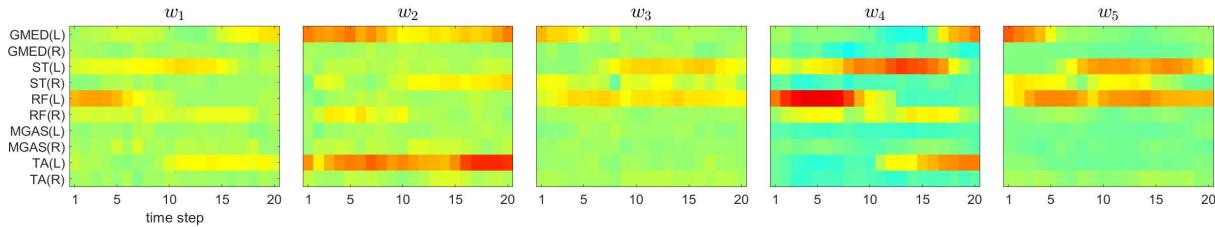


그림 5. Not-TC 조건에서 추출된 머슬시너지 (시너지 개수: 5개)

Fig. 5. Extracted muscle synergy under Not-TC condition (Number of synergy: 5)

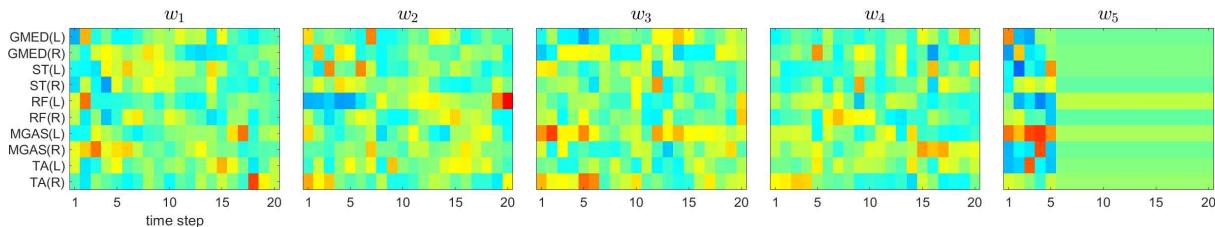


그림 6. TC 조건에서 추출된 머슬시너지 (시너지 개수: 5개)

Fig. 6. Extracted muscle synergy under TC condition (Number of synergy: 5)

로축은 근육의 활성도를 의미한다. 그림에서 볼 수 있듯이, gait 동작을 수행하는 데 관여하는 주요 근육들의 활성화가 전형적인 패턴을 보여주는 것을 볼 수 있다[12]. 이를 통해 사용된 근전도 데이터의 타당성을 검증하였다.

### 3.2 머슬시너지 추출

45개의 전처리된 근전도 데이터  $\mathbf{M}$ 을 사용하여 2.2절에서 소개된 방법에 따라, 텐서형 데이터  $\mathbf{T}$ 를 제작하였고,  $\mathbf{T}$ 에서 제약조건으로 사용할  $\mathbf{S}_i$ 를 추출하였다. 머슬시너지의 타임 스텝  $k$ 은 20으로 설정하였으며,  $n$ 을 4~8까지로 설정하여 머슬시너지를 추출하였다. 머슬시너지 추출은 1개의 운동 주기에 대해서 추출하였고, TC를 적용하지 않은 Not-TC 머슬시너지와 TC를 적용한 TC 머슬시너지의 두 경우로 나누어 추출하였다.  $w_i$ 와  $c_i$ 의 초기값은 모두 0.5로 초기화 하였으며,  $\tau_i$ 는 0으로 초기화 하였다. 실험을 진행한 computational 환경은 다음과 같다. CPU는 Intel(R) Core(TM) i9-10900을 사용하였으며, RAM은 24GB이다. 최적화는 MATLAB(R2021a) 프로그램의 fmincon 함수를 사용하였으며, 최적화 관련 파라미터는 표 1과 같이 사용하였다. 두 경우의 추출된 시너지 비교를 위해 최적화 소요 시간

표 1. fmincon 함수의 파라미터

Table 1. Parameters of fmincon function.

Parameter	Value
MaxFunEvals	inf
MaxIter	300
TolFun	1e-03
TolX	1e-05

(elapsed time)과 variance accounted for(VAF)를 사용하였다.

## 4. 결과 및 토의

그림 5와 6는 각각 TC를 적용하지 않았을 때와 적용하였을 때의 머슬시너지 추출 결과를 보여주고 있다. 두 경우 모두 머슬시너지의 개수는 5개이고, 가로축은 타임 스텝, 세로축은 채널을 의미한다. 타임 스텝은 1~20까지 표현하고 있다. 채널은 위쪽부터 GMED, ST, RF, MGAS, TA 근육 순서이며, 흘수 채널인 왼쪽 다리는 (L), 짹수 채널인 오른쪽 다리는 (R)로 표기한다. 근육의 활성화 정도는 0에서 1 사이의 값으로 표현하며, 0에 가까울수록 파란색, 1에 가까울수록 빨간색을 가진다. 그림 7은 머슬시너지 개수에 따른 최적화 소요 시간을 보여준다. 가로축은 머슬시너지의 개수, 세로축은 소요 시간을 나타내며 단위는 분이다. 파란 막대는 Not-TC 머슬시너지, 빨간색 막대는 TC 머슬시너지의 추출에 든 시간을 나타낸다. 그림 8은 머슬시너지 개수에 따른 VAF를 보여준다. 가로축은 머슬시너지의 개수, 세로축은 VAF 값을 보여준다. 파란색 막대는 Not-TC, 빨간색 막대는 TC 머슬시너지 추출이 진행됨에 따른 VAF의 변화를 나타낸다. 그림 9는 근육 관계 매트릭스  $\mathbf{S}_i$ 와 머슬시너지를 통해 만들어진 근육 관계 매트릭스  $\hat{\mathbf{S}}_i$ 의 차이 값을 보여준다. 차이 값은 식 (6)에 있는 제약조건식을 사용하여 계산하였으며, 머슬시너지가 제약조건을 얼마나 만족했는지를 보여준다. 가로축은 추출된 머슬시너지를 의미하며, 세로축은  $\mathbf{S}_i$ 와  $\hat{\mathbf{S}}_i$ 의 차이 값을 보여준다.

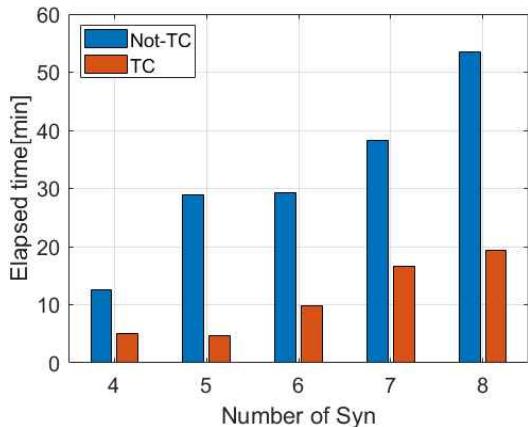


그림 7. 머슬시너지 개수에 따른 최적화 소요 시간  
Fig. 7. The elapsed times to complete an optimization process according to the number of muscle synergy

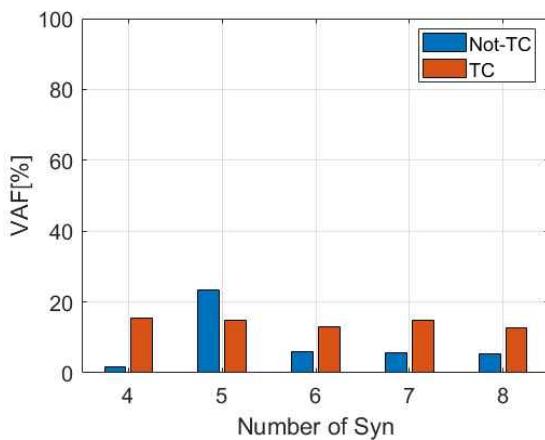


그림 8. 머슬시너지 개수에 따른 VAF  
Fig. 8. The VAFs according to the number of muscle synergy

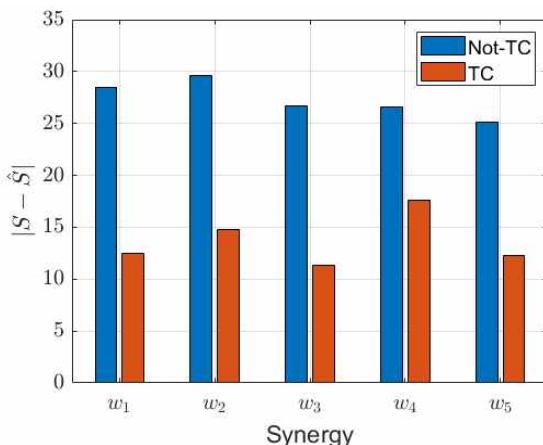


그림 9. 근육 관계 매트릭스  $S_i$ 와 추출된 머슬시너지로부터 복원된  $\hat{S}_i$ 의 차이 그래프(시너지 개수: 5개)  
Fig. 9. Bar graphs to represent differences between muscle relationship matrix  $S_i$  and  $\hat{S}_i$  reconstructed from muscle synergy (Number of synergy: 5)

#### 4.1 Not-TC 머슬시너지 결과 분석

Not-TC 머슬시너지의 경우 머슬시너지의 모습이 모호하지만, 어떤 근육이 주로 사용되고 있는지는 구분할 수 있다.  $w_1, w_4$ 는 RF(L)이 먼저 사용되고, ST(L), GMED(L)근육이 사용되는 것을 확인할 수 있다.  $w_2$ 는 GMED(L)근육이 사용되고, TA(L) 근육이 주로 사용되는 것을 볼 수 있다. 다음으로  $w_3, w_5$ 는 GMED(L) 사용 후, ST(L)과 RF(L)이 주로 사용되고 있다. 그림 7에서 나타나듯이 소요 시간이 증가하는 것을 확인할 수 있다. 이는 머슬시너지의 개수가 증가함에 따라 최적화 할 변수의 개수가 증가하기 때문이다. VAF는 그림 8에서 볼 수 있듯, 머슬시너지의 개수가 5개 일 때 가장 큰 값을 가지며, 5개가 아닐 경우 10%가 되지 않는 것을 볼 수 있다.

#### 4.2 TC 머슬시너지 결과 분석

TC 머슬시너지의 경우 머슬시너지에서 근육이 활성화되는 부분을 구분하기 어려워, 머슬시너지가 운동에서 어떤 역할을 하고 있는지 구분할 수 없다. 최적화 소요 시간의 경우 그림 7과 같이 머슬시너지의 개수가 증가할 때, 최적화에 드는 시간도 증가하는 것을 볼 수 있다. 이는 Not-TC 머슬시너지 추출 때와 마찬가지로, 최적화 할 변수의 개수가 증가하기 때문이다. VAF의 경우, 머슬시너지의 개수에 상관없이 모두 10~15% 사이의 값을 가지는 것을 볼 수 있다.

#### 4.3 Not-TC 머슬시너지와 TC 머슬시너지의 비교

머슬시너지의 개수가 5개 일 때, Not-TC 머슬시너지의 경우 각 머슬시너지에서 주로 사용되는 근육을 해석할 수 있다. 하지만, TC 머슬시너지의 경우 주로 사용되는 근육을 확인할 수 없었다. 또한, 머슬시너지의 개수가 5개 일 때, VAF가 Not-TC의 경우는 23%이지만, TC의 경우 14%인 것을 볼 수 있다. 이러한 결과가 나타난 이유는, 그림 9을 통해 해석할 수 있다. Not-TC의 경우보다 TC의 경우가 제약조건을 더 잘 만족하는 것을 확인할 수 있으며, 제약조건을 만족시키는 과정에서 VAF가 낮아지기 때문이다. 결과적으로, TC를 사용하여 머슬시너지를 추출할 경우가 제약조건이 더 잘 반영한다는 것을 확인할 수 있었다. 하지만, 기대와 달리 근육 관계 매트릭스가 머슬시너지 최적화의 제약조건으로 사용되기는 어렵다는 것을 볼 수 있었다. 그 이유는,  $S_i$ 와  $\hat{S}_i$ 의 차이 값이 작은 값으로 수렴하지 못하고 있기 때문이다. 머슬시너지 최적화 속도의 경우, 모든 경우에 대해서 TC를 사용했을 때 더 빠른 것을 확인할 수 있다.

Not-TC의 경우 4~8개의 머슬시너지를 최적화하는 데, 평균 34분이 소요되었지만, TC를 사용하면 평균 11분이 소요되는 것을 볼 수 있다. 결과적으로 TC를 사용하여 제약조건이 있는 머슬시너지를 최적화하면 평균적으로 3배 빠르게 머슬시너지를 추출한다는 것을 알 수 있다. VAF의 경우 머슬시너지의 개수가 5개일 때를 제외하고, TC 머슬시너지가 더 높은 것을 알 수 있다. 머슬시너지의 개수가 4~8개 일 때, VAF의 평균은 Not-TC와 TC의 경우가 각각 8.4%, 14.1%이다. 이를 통해, TC를 사용하면 약 1.6배 높은 VAF를 얻을 수 있음을 확인하였다.

## 5. 결론 및 향후 연구

본 논문은 생체역학적 제약조건이 있는 time-varying 머슬시너지 추출 문제를 TC를 적용하여 최적화하였으며, TC를 적용하지 않았을 때와 적용했을 때 추출된 머슬시너지 결과를 비교 분석하였다. 최적화에 사용할 제약조건을 추출하기 위해 sEMG를 3 차원 텐서형 데이터로 제작하고, 텐서형 데이터를 비부정 행렬 인수분해하여 근육 관계 매트릭스를 추출하는 방법론을 소개하였다. 그리고 근육 관계 매트릭스를 머슬시너지의 제약조건으로 사용하며, TC를 적용하여 머슬시너지 추출 문제를 메인/서브 시스템 최적화 과정으로 나누어 진행하는 기법을 제안하였다. TC를 적용한 경우 TC를 적용하지 않았을 때보다 최적화 소요 시간이 적게 들었으며, VAF의 값이 높게 나타나는 것을 확인하였다. 그러나, 근육 관계 매트릭스를 머슬시너지 최적화의 제약조건으로 사용하기 어렵다는 결과를 확인하였다. 결과적으로, 제약조건이 있는 머슬시너지 추출은 TC를 적용했을 때 최적화 관점에서 더 효율적이며, 근육 관계 매트릭스가 제약조건으로 사용되기에 어렵다는 결과를 얻었다. 연구결과를 바탕으로, 향후 연구에서는 근골격계의 구조와 더불어 운동 생리학적 상관관계가 포함된 다른 제약조건을 선택하여 TC를 적용해 볼 것이다. 또한, 사람의 운동을 머슬시너지라는 모듈로 해석한다면 개별 근육으로 해석할 때보다 정보량이 줄어들게 된다. 그려므로, 머슬시너지의 모듈성을 사용한 human-machine interface 구현 방법론에 관해 연구를 진행할 것이다.

## Conflict of Interest

저자는 본 논문에 관련된 어떠한 잠재적인 이해상충도 없음을 선언한다.

## References

- [1] N. A. Bernstein, *The Co-ordination and Regulation of Movements*, Oxford, Pergamon, 1967.
- [2] A. d'Avella and E. Bizzi, "Shared and specific muscle synergies in natural motor behaviors," *Proceedings of the National Academy of Sciences*, vol. 102, pp. 3076–3081, Feb., 2005.
- [3] A. d'Avella and F. Lacquaniti, "Control of reaching movements by muscle synergy combinations," *Frontiers in Computational Neuroscience*, vol. 7, no. 42, pp. 1–7, 2013.
- [4] S. A. Chvatal and L. H. Ting, "Common muscle synergies for balance and walking," *Frontiers in computational neuroscience*, vol. 7, no. 48, 2013.
- [5] H. M. Kim, N. F. Michelen, P. Y. Papalambros, and T. Jiang, "Target cascading in optimal system design," *Journal of Mechanical Design*, vol. 125, pp. 474–480, 2003.
- [6] H. M. Kim, D. G. Rideout, P. Y. Papalambros, and J. L. Stein, "Analytical Target Cascading in Automotive Vehicle Design," *Journal of Mechanical Design*, vol. 125, pp. 481–489, 2003.
- [7] J. Allison, D. Walsh, M. Kokkolaras, P. Y. Papalambros, and M. Cartmell, "Analytical Target Cascading in Aircraft Design," *44th AIAA aerospace sciences meeting and exhibit*, Reno, Nevada, United States, pp. 1–9, Jan., 2006.
- [8] J. Camargo, A. Ramanathan, W. Flanagan, and A. Young, "A comprehensive, open-source dataset of lower limb biomechanics in multiple conditions of stairs, ramps, and level-ground ambulation and transitions," *Journal of Biomechanics*, vol. 119, pp. 1–9, 2021.
- [9] H. J. Hermens, R. Merletti, and B. Freriks, *SENIAM : European recommendations for surface electromyography : results of the SENIAM project*, 2nd Eds, Roessingh Research and Development, 1999.
- [10] V. Dietz, R. Müller, and G. Colombo, "Locomotor activity in spinal man: significance of afferent input from joint and load receptors," *Brain*, vol. 125, pp. 2626–2634, 2002.
- [11] T. A. Exell, M. J. Gittoes, G. Irwin, and D. G. Kerwin, "Gait asymmetry: Composite scores for mechanical analyses of sprint running," *Journal of biomechanics*, vol. 45, pp. 1108–1111, 2012.
- [12] S. J. Crenshaw and J. G. Richards, "A method for analyzing joint symmetry and normalcy, with an application to analyzing gait," *Gait & Posture*, vol. 24, pp. 515–521, 2006.

## 저 자 소 개



**김장현 (Janghyeon Kim)**

2022 : 연세대학교 미래캠퍼스

컴퓨터공학부 공학사

2022~현재 : 연세대학교 미래캠퍼스

전산학과 석사과정

관심분야 : 최적화, 강화학습, 인공지능, 제어이론

ORCID Number : 0000-0002-7327-9706

E-mail : janghyeonk@yonsei.ac.kr



**윤한얼(Han UI Yoon)**

2014년 : 일리노이대학교 어바나-샴페인

전기컴퓨터공학과 공학박사

2014년~2016년 : 텍사스 A&M 대학교

Postdoctoral research  
associate

2017 : 텍사스 A&M 대학교

조교수(강의전담)

2017년 10월~2020년 2월:

한국생산기술연구원 로봇그룹 선임연구원

2020년 3월~현재 : 연세대학교

미래캠퍼스

소프트웨어학부

조교수

관심분야 : 로봇 패스 플래닝, 메타러닝/퓨샷러닝,  
XAI, 머신러닝 기반 생체신호분석,  
로봇 모델링 및 제어

ORCID Number : 0000-0001-8870-3103

E-mail : huyoon@yonsei.ac.kr