

## 사람의 운동 분석을 위한 교대 최적화를 사용한 머슬시너지 추출 방법론

### A Method of Extracting Muscle Synergies via Alternating Optimization for Human Motion Analysis

김장현\*<sup>ID</sup>, 윤한얼\*\*†<sup>ID</sup>

Janghyeon Kim and Han Ul Yoon<sup>†</sup>

\*연세대학교 미래캠퍼스 뉴로로보틱스 연구실 연구원

\*\*연세대학교 미래캠퍼스 소프트웨어학부 교수

\*Researcher, Human Assistive Neurorobotics Lab., Yonsei University Mirae Campus

\*\*Professor, Division of Software, Yonsei University Mirae Campus

#### 요약

머슬시너지는 사람의 중추신경계가 신체를 제어할 때 사용하는 미리 정의된 근육 그룹을 말한다. 일반적으로, 머슬시너지는 표면 근전도(surface electromyography, sEMG)를 비음수 행렬 인수분해하여 획득한다. 이때 비음수라는 조건으로 인해, 통상적인 최소자승법 기반 방법론이 아닌, 제약조건이 있는 최적화 문제(constrained optimization problem)로 정의하는 접근법을 많이 이용한다. 본 논문에서는 머슬시너지 추출을 위한 최적화 문제를 정의하고, 이에 대해 수치적으로 최적해를 구하는 교대(alternating) 최적화 기반 방법론을 보인다. 먼저, 시불변(time invariant)과 시변(time variant)의 두 종류 머슬시너지의 개념과 sEMG를 이용한 수학적 정의에 대해 논한다. 다음으로, 머슬시너지를 추출하기 위해 시불변과 시변 머슬시너지에 따라 각각의 교대 최적화 문제를 정의한다. 특히, 정의되는 목적 함수와 제약조건으로 부과되는 비음수 조건을 중심으로 소개한다. 실험에서는 사람의 보행 시 양쪽 다리에서 측정된 sEMG 데이터로부터 시불변과 시변 머슬시너지를 추출을 수행한다. 최종적으로, 추출된 머슬시너지들을 보이고, 이들을 이용한 사람의 보행 운동을 분석이 가능한 것을 확인한다.

**키워드 :** 머슬시너지, 비음수 행렬 인수분해, 제약조건 최적화, 교대 최적화

#### Abstract

Muscle synergy refers to coordinated muscle groups employed by the central nervous system to control human movements. In general, the muscle synergy is obtained by decomposing surface electromyography(sEMG) followed by non-negative matrix factorization(NMF). The condition of non-negative matrix entries allows us not to adopt a conventional least square-based method but to reformulate the synergy extraction problem as a constrained optimization problem. In this paper, we present methodologies to formulate a muscle synergy extraction problem as an optimization problem; accordingly, we also introduce a numerical approach, which is designed based on an alternating optimization, to solve the formulated optimization problem. First, we discuss the concept of the two types of muscle synergy - time invariant and time variant - as well as their mathematical definitions in terms of sEMG. Next, we define the two alternating optimization problems to extract a time invariant and a time variant muscle synergies, respectively. Specifically, we focus on introducing an objective function and an imposed non-negative matrix entry constraint for each muscle synergy type. In experiment, the extractions of the time invariant and the time variant synergy are performed with the sEMG data of the human legs being measured while walking normally. Consequently, we present the resulting extracted muscle synergies and substantiate the feasibility of the extracted muscle synergies as a tool to analyze human walking movement.

**Key Words :** Muscle Synergy, Non-negative Matrix Factorization, Constrained Optimization, Alternating Optimization

Received: Aug. 14, 2025  
Revised : Sep. 30, 2025  
Accepted: Sep. 30, 2025  
†Corresponding author  
(huyoon@yonsei.ac.kr)

감사의 글 : 이 성과는 정부(산업통상자원부, 교육부)의 재원으로 한국산업기술평가관리원 소재부품기술개발사업(No. RS-2024-00418941) 및 강원특별자치도 강원RISE센터 지역혁신중심대학지원체계(2025-RISE-10-006)의 지원에 의해 수행되었습니다. 연구비 지원에 감사드립니다.

 This is an Open-Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License (<http://creativecommons.org/licenses/by-nc/3.0>) which permits unrestricted noncommercial use, distribution, and reproduction in any medium, provided the original work is properly cited.

## 1. 서 론

머슬시너지(muscle synergy)란 사람의 중추신경계(central nervous system)가 신체를 제어하기 위해 사용하는 미리 정의된 근육 모듈을 말한다[1]. 근육 모듈을 사용하여 신체를 제어하는 것은 개개의 근육을 통해 신체를 제어하는 것에 비해 정보량 측면에서 효율적이다. 이러한 이유로 머슬시너지를 사용한 운동 능력 분석 및 로봇 제어와 관련된 다양한 연구가 진행되고 있다[2][3]. 머슬시너지는 표면근전도(surface electromyography, 이하 sEMG) 신호를 비음수 행렬 분해(non-negative matrix factorization, 이하 NMF)하여 획득할 수 있다[2][3][4].

NMF는 단순 행렬 분해(matrix factorization)와 다르게 비음수(non-negative)라는 제약조건(constraint)이 존재하며, 이는 선형대수에서 사용되는 행렬 분해 알고리즘 사용을 제한한다[4]. 이러한 이유로 NMF는 제약조건 최적화(constrained optimization) 문제로 정의되어, 분해될 두 행렬의 교대 최적화(alternating optimization)를 통해 최적해를 구하게 된다[5][6][7]. NMF를 최적화 기법으로 접근하는 방법을 사용하여, Z. Yuan과 E. Oja는 이미지 압축과 특징 추출을 수행하였고, Kang et al.은 원신호로부터 목표하는 신호(target source)를 추출하였다[8][9]. 선행 연구들처럼, sEMG로부터 머슬시너지를 추출하기 위한 NMF를 최적화 문제로 정의한다면, 다양한 최적화 기법을 적용할 수 있을 것으로 기대된다.

머슬시너지는 표현되는 수학적 정의에 따라 두 가지 종류로 나뉜다. Time-invariant(이하, TI) 머슬시너지는 시간에 대하여 고정된 벡터로 표현되며, time-varying(이하, TV) 머슬시너지는 시간에 따라 변하는 커브 형태로 표현된다[10][11]. 두 종류의 머슬시너지 모두 sEMG 기반 행동 분석 및 분류, 그리고 생체신호를 사용한 로봇 제어와 같은 분야에서 사용되고 있다[11][12][13]. 시간에 대한 수학적 모델에 따라 머슬시너지는 두 가지 방식으로 표현되지만, 두 머슬시너지 모두 sEMG를 NMF 하여 추출된다. 따라서, 머슬시너지 추출 문제는 머슬시너지의 종류와 관계없이 여전히 최적화 문제로 정의하고 해결할 수 있다.

본 논문은 머슬시너지 추출을 위한 NMF 과정을 교대(alternative) 최적화 방법으로 해결하고, 획득한 머슬시너지를 사용하여 사람의 보행 운동(gait cycle) 분석 예시를 보인다. 본 연구는 사람의 생체신호를 사용하여 로봇을 제어하기 위한 human-robot interface(HRI)의 개발에 있어 선행되는 연구이며, 논문에서 사용하는 방법론을 통해 사람의 운동을 머슬시너지를 기반하여 분석할 수 있음을 확인한다. sEMG는 머슬시너지와 활성화 커브/계수로 표현이 되며, 이 두 요소는 모두 비음수 조건을 갖는다. 머슬시너지 추출 문제는 sEMG를 머슬시너지와 활성화 커브/계수로 분해하는

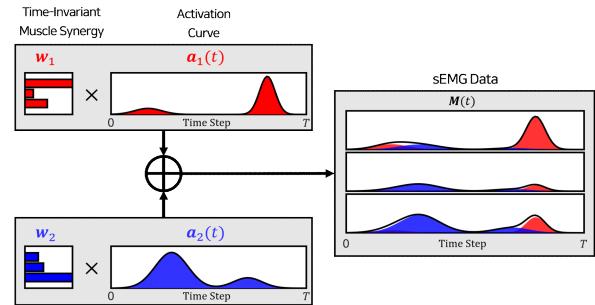


그림 1.  $N_{ch} = 3$ ,  $N_{sym} = 2$ 인 경우의 TI 머슬시너지 예시

Fig. 1. The example of the TI muscle synergy when  $N_{ch} = 3$  and  $N_{sym} = 2$ .

NMF 문제와 같으며, 논문에서는 제약조건이 있는 최적화 문제로 NMF를 정의하여 교대(alternative) 최적화 방법론으로 두 요소를 최적화(추출)할 것이다.

논문의 구성은 다음과 같다. 2장에서는 TI/TV 머슬시너지의 수학적 정의를 sEMG를 사용하여 보인다. 3장에서는 2장에서 정의한 TI/TV 머슬시너지의 정의를 사용하여 머슬시너지 추출을 위해 최적화해야 하는 목적함수(objective function)와 제약조건(constraint)을 정의한다. 이어서, 목적함수를 사용하여 머슬시너지 추출 문제를 최적화 문제로 정의하고, 최적화 문제를 풀기 위한 교대 최적화 프레임워크를 보인다. 4장에서는 sEMG 데이터를 사용하여 TI/TV 머슬시너지 추출 실험을 진행하고, 5장에서는 추출된 각 머슬시너지에 대하여 결과를 비교 분석한다. 마지막으로 6장에서 결론 및 향후 연구에 대하여 다룬다.

## 2. 두 종류의 머슬시너지의 수학적 정의

머슬시너지를 추출할 sEMG 데이터를  $\mathbf{M} \in \mathbb{R}_+^{N_{ch} \times T}$  으로 쓴다. 여기서  $N_{ch}$  와  $T$ 는 각각 sEMG의 채널 수와 타임 스텝의 길이를 의미한다. 머슬시너지의 개수는  $N_{sym}$  으로 쓰며,  $\mathbf{w}_n$  는  $n = 1, 2, \dots, N_{sym}$  번째 머슬시너지를 나타낸다.

### 2.1 Time-Invariant(TI) 머슬시너지의 수학적 정의

TI 머슬시너지는 시간에 대하여 고정(time-invariant)된 벡터 형태를 가지며,  $\mathbf{w}_n \in \mathbb{R}_+^{N_{ch} \times 1}$  로 표현된다. TI 머슬시너지 벡터에서 채널 차원은 해당 근육의 활성화 정도를 의미한다. 머슬시너지에 상응하는 활성화 커브는  $\mathbf{a}_n \in \mathbb{R}_+^{1 \times T}$  로 표현하며, TI 머슬시너지가 시간에 따라 얼마나 활성화되었는지를 나타낸다. 머슬시너지와 활성화 커브를 사용하여 sEMG를 표현하면 다음과 같다.

$$\mathbf{M}(t) = \sum_{n=1}^{N_{sym}} \mathbf{w}_n \mathbf{a}_n(t). \quad (1)$$

그림 1은 채널의 개수가 3개, 머슬시너지의 개수가 2

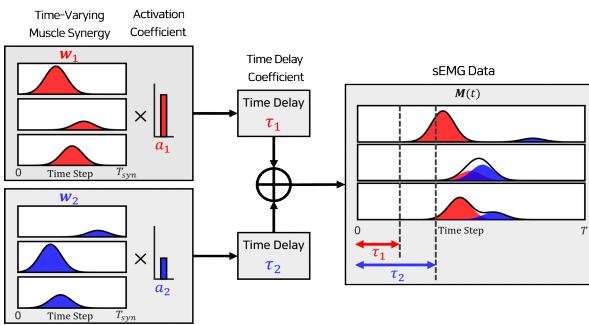
그림 2.  $N_{ch} = 3$ ,  $N_{syn} = 2$ 인 경우의 TV 머슬시너지 예시

Fig. 2. The example of the TV muscle synergy when  $N_{ch} = 3$  and  $N_{syn} = 2$ .

개인 경우, TI 머슬시너지의 예시를 보여준다. 그림에서 볼 수 있는 것처럼, TI 머슬시너지는 시간에 대하여 고정된 벡터의 형태를 가지며, 머슬시너지마다 각 근육의 활성화 정도가 다른 것을 볼 수 있다. 또한 활성화 커브를 통해 머슬시너지가 시간에 따라 얼마나 사용되는지 알 수 있다.

## 2.2 Time-Varying(TV) 머슬시너지의 수학적 정의

TV 머슬시너지는 시간에 따른 함수 형태를 가지며,  $w_n \in \mathbb{R}_{+}^{N_{ch} \times T_{syn}}$ 로 표현한다. 여기서  $T_{syn}$ 은 TV 머슬시너지의 타임 스텝 길이를 의미한다.  $a_n \in \mathbb{R}_{+}$ 와  $\tau_n \in \mathbb{R}_{+}$ 는 각각 머슬시너지와 상응하는 활성화 계수와 지연시간 계수를 의미한다. TV 머슬시너지, 활성화 계수, 지연시간 계수를 사용하여 sEMG를 표현하면 아래와 같이 쓸 수 있다:

$$\mathbf{M}(t) = \sum_{n=1}^{N_{syn}} a_n w_n(t - \tau_n). \quad (2)$$

앞선 TI 머슬시너지와는 다르게, 시간에 대한 파라미터  $t$ 가 머슬시너지에 있는 것을 볼 수 있으며, 활성화 계수는 단순하게 스칼라 곱 역할을 하고, 지연시간 계수는 시프트 연산에 사용이 된다. 그림 2는 채널의 개수가 3개, 머슬시너지의 개수가 2개인 경우, TV 머슬시너지의 예시를 보여준다. 그림에서 볼 수 있는 것처럼, TV 머슬시너지는  $T_{syn}$ 라는 고정된 길이를 갖는 시간에 대한 함수 형태를 보인다. 또한 sEMG가 계산될 때 활성화 계수가 머슬시너지에 곱해지고, 시간지연 계수만큼 시간 축에서 미뤄져(delay), sEMG를 구성하는 데 사용되는 것을 볼 수 있다.

## 3. 머슬시너지 추출 최적화 문제 정의

### 3.1 Time-Invariant(TI) 머슬시너지의 추출

수식 1로부터 TI 머슬시너지  $w_n$ 과 활성화 커브  $a_n$ 를 사용하여 예측한 sEMG를  $\hat{\mathbf{M}}$ 로 쓴다고 하자. sEMG 데이터  $\mathbf{M}$ 과  $\hat{\mathbf{M}}$  사이의 오차를 목적함수

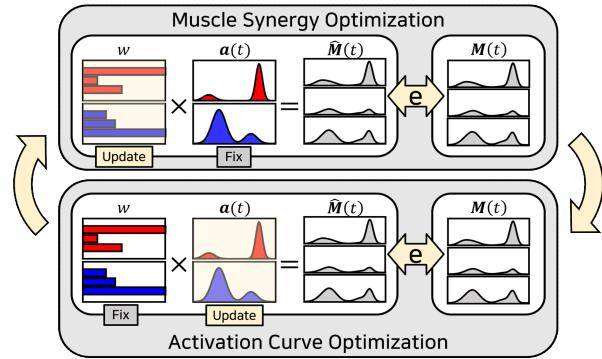


그림 3. TI 머슬시너지 교대 최적화 프레임워크

Fig. 3. The framework for solving alternating optimization to extract TI muscle synergy

$e(\mathbf{M}, \hat{\mathbf{M}})$ 로 정의한다면, 해당 목적함수를 최소화함으로써 sEMG를 구성하는  $w_n$ 과  $a_n$ 를 획득할 수 있을 것이다. 머슬시너지와 활성화 커브의 조건에 따라  $w_n$ 과  $a_n$ 는 비음수 제약조건으로 표현되어야 하며, 위에서 언급한 최적화 문제는 아래와 같이 정의된다.

$$\begin{aligned} \min_{\substack{\mathbf{w}_n, \mathbf{a}_n \\ n=1,2,\dots,N_{syn}}} & e(\mathbf{M}, \hat{\mathbf{M}}) = \sum_i \sum_k (\mathbf{M}(i,j) - \hat{\mathbf{M}}(i,j))^2 \\ \text{sub to. } & \hat{\mathbf{M}}(t) = \sum_{n=1}^{N_{syn}} \mathbf{w}_n \mathbf{a}_n(t) \\ & \mathbf{w}_n \geq 0, \mathbf{a}_n \geq 0, n = 1, 2, \dots, N_{syn}. \end{aligned} \quad (3)$$

최적화 문제에서 최적화해야 하는 변수는  $N_{syn}$  개의  $w_n$  그리고  $a_n$  벡터이다. 이때, 두 종류의 변수에 대하여 최적화를 동시에 진행하게 된다면, 두 변수를 모두 고려한 목적함수가 convex 하지 않기 때문에 최적해를 찾기 어려워진다[4]. 이러한 이유로 두 변수를 한 번에 최적화하지 않고, 하나의 변수를 최적화할 때 다른 변수는 상수(constant)로 간주하는 교대 최적화(alternating optimization) 기법을 사용한다. 그림 3은 TI 머슬시너지 최적화 문제를 풀기 위한 교대 최적화 프레임워크 그림을 보여준다. 그림 3에서 볼 수 있듯, 교대 최적화 과정은 머슬시너지 업데이트와 활성화 커브 업데이트 구조로 나뉘어 있다. 머슬시너지 업데이트 시에는 활성화 커브는 업데이트되지 않고 고정되어 있으며, 머슬시너지는 목적함수  $e(\mathbf{M}, \hat{\mathbf{M}})$ 을 줄이는 방향으로 최적화가 진행된다. 반대로, 활성화 커브 업데이트 시에는 머슬시너지가 고정되고, 활성화 커브가 목적함수  $e(\mathbf{M}, \hat{\mathbf{M}})$ 을 줄이는 방향으로 최적화된다.

### 3.2 Time-Varying(TV) 머슬시너지의 추출

수식 2로부터 TV 머슬시너지  $w_n$ , 활성화 계수  $a_n$ , 그리고 지연시간 계수  $\tau_n$ 를 사용하여 예측한 sEMG를  $\hat{\mathbf{M}}$ 로 쓰자. 앞서 TI 머슬시너지 최적화 문제와 같이 sEMG 데이터  $\mathbf{M}$ 과  $\hat{\mathbf{M}}$  사이의 오차를 목적함수로 정의한다. 또한,  $w_n$ ,  $a_n$ , 그리고  $\tau_n$ 가 비음수임을 제약조건으로 설정한다. 위에서 언급한 TV 머슬시너지 추출을 최적화 문제로 정의하면 다음과 같이 쓸 수 있다:

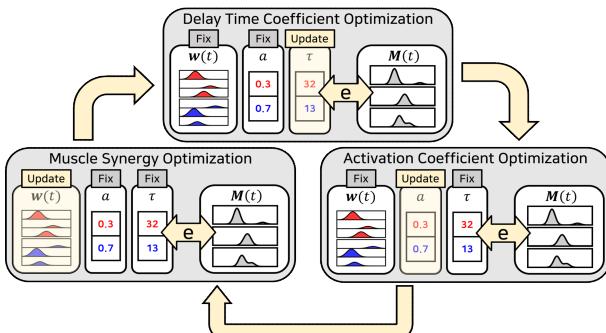


그림 4. TV 머슬시너지 교대 최적화 프레임워크  
Fig. 4. The framework for solving alternating optimization to extract TV muscle synergy

$$\begin{aligned} \min_{\mathbf{w}_n, \alpha_n} & \sum_{n=1,2,\dots,N_{syn}}^{} \sum_{i,j} (\mathbf{M}(i,j) - \hat{\mathbf{M}}(i,j))^2 \\ \text{sub to. } & \hat{\mathbf{M}}(t) = \sum_{n=1}^{N_{syn}} \alpha_n \mathbf{w}_n(t - \tau_n) \end{aligned} \quad (4)$$

$$\mathbf{w}_n \geq 0, \alpha_n \geq 0, \tau_n \geq 0, n = 1, 2, \dots, N_{syn}.$$

TI 머슬시너지의 경우와 마찬가지로, 위 최적화 문제에는 너무 많은 변수가 존재하며, 효율적인 문제 해결을 위해 교대 최적화 기법을 사용한다[2]. 그림 4는 TV 머슬시너지 최적화 문제를 풀기 위한 교대 최적화 프레임워크 그림을 보여준다. 그림 4에서 볼 수 있는 것처럼, 교대 최적화 과정은 각 변수에 따라서 세 단계로 구분되며, 각 단계에서는 최적화하는 변수를 제외하고는 상수로 간주한다.

## 4. 실험: 머슬시너지 추출 및 분석

### 4.1 sEMG 데이터 및 전처리

TI/TV 머슬시너지 추출을 위하여, Camargo et al.의 연구에서 사용된 사람의 보행 시 나타나는 다리 근육 sEMG 데이터를 사용하였다[14]. 데이터 측정에서 사람은 평지에서 정상 속도로 보행을 수행하였으며, 11채널 sEMG 센서(Biometrics, Ltd. Newport, UK)를 다리 근육에 부착하여 1KHz의 샘플링 레이트로 데이터를 수집하였다. 센서를 부착한 다리 근육은 SENIAM (surface EMG for non-invasive assessment of muscles) 프로젝트를 따랐다[15].

본 논문은 안쪽장딴지근육(medial gastrocnemius, MG), 앞정강근(tibialis anterior, TA), 가자미근(soleus, SOL), 대퇴이두근(biceps femoris, BF), 반힘줄근(semitendinosus, ST) 그리고 중둔근(gluteus medius, GMED)과 같은 6개의 채널만 머슬시너지 추출에 사용하였다. 사람의 보행 주기(gait cycle)에서 오른쪽 다리의 발꿈치 닿기(heel strike)부터 발끝 밀기(toe off)까지를 한 번의 시행(trial)으로 간주하여 실험에 사용한다. 그림 5는 보행에 사용되는 주요 다리 근육들의 활

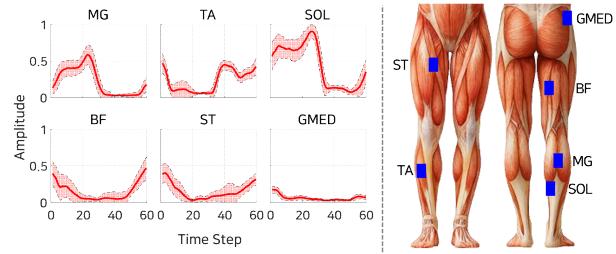


그림 5. 보행에 사용되는 주요 다리 근육들의 활성도  
그래프(왼쪽)와 sEMG 센서 부착 위치(오른쪽)  
Fig. 5. The activation graphs of major low-limb muscles during gait(left) and placement of sEMG sensor(right)

성도 그래프(왼쪽)와 sEMG 센서 부착 위치(오른쪽)를 보여준다. 왼쪽 그림에서 가로축은 타임스텝을 의미하며, 세로축은 0부터 1 사이로 정규화된 근육의 활성화 정도를 보여준다. 빨간색 실선과 검정색 실선은 각각 45개의 데이터에 대하여 평균과 표준편차를 의미한다. 오른쪽 그림은 앞서 언급한 근육들을 측정한 센서의 위치를 보여준다.

머슬시너지 추출을 위한 sEMG 신호는 아래와 같은 과정을 통해 근육 활성도로 계산되었다. 먼저 전압으로 표현되는 원본 sEMG 데이터에 절댓값을 취하고, 윈도우사이즈를 80으로 설정한 이동 평균 필터를 적용한다. 이어서, 타임 스텝이 60이 되도록 적분하고 마지막으로 채널 간 정규화를 진행하여 45개의 sEMG 데이터  $\mathbf{M} \in \mathbb{R}^{6 \times 60}$ 을 획득한다. 그림 5는 보행에서 사용되는 근육 채널별 활성화 정도를 보여준다. 가로축은 타임 스텝, 세로축은 활성화된 정도를 표현하며 0과 1 사이 값으로 정규화되어 있다. 그래프에서 빨간색 실선과 검은색 점선은 각각 45개 sEMG 데이터에 대한 평균과 표준편차를 나타낸다. 그림에서 볼 수 있는 것처럼, 발꿈치 닿기부터 발끝 밀기까지의 데이터가 일관성을 보이는 것을 볼 수 있으며, 시간에 따라 주로 사용되는 근육이 다른 것을 확인할 수 있다.

### 4.2 TI/TV 머슬시너지 추출

TI 머슬시너지 추출을 위해 45개의  $\mathbf{M} \in \mathbb{R}^{6 \times 60}$ 을 연 결(concatenation)하여 만들어진 데이터  $\mathbf{M} \in \mathbb{R}^{6 \times 2700}$ 을 3.1에서 소개한 최적화 문제에 사용한다. 이어서, 그림 3에 나타난 것처럼 TI 머슬시너지  $\mathbf{w}_n$ 와 활성화 커브  $\alpha_n$ 의 교대 최적화를 과정을 통해 TI 머슬시너지를 추출하게 된다. TV 머슬시너지 추출 실험에서도 45개의  $\mathbf{M} \in \mathbb{R}^{6 \times 60}$ 을 모두 사용한다. 이때, 모든 데이터에서 TV 머슬시너지  $\mathbf{w}_n$ 는 동일한 벡터를 사용하지만, 활성화 계수  $\alpha_n$ 와 지연시간 계수  $\tau_n$ 는 각 데이터에 대하여 최적화를 진행한다. 그림 4에 나타난 것처럼 TV 머슬시너지 또한 교대 최적화를 통해 추출되게 된다.  $N_{syn}$ 은 3~6으로 설정하였으며, 모든 최적화 과정에서 머슬시너지와 그에 상응하는 활성화 커브/계수는 0.5로 초기값을 설정하였다. TV 머슬시너지의 경우,  $T_{syn} = 30$

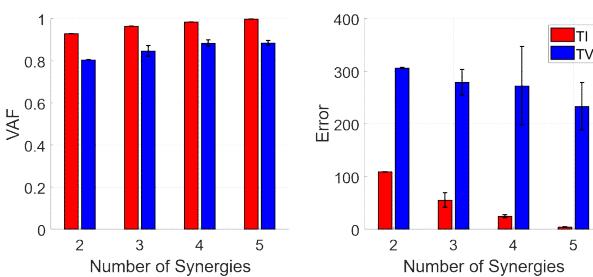


그림 6. 머슬시너지 개수에 따른 VAF 값(왼쪽)과 목적함수  $e(\mathbf{M}, \hat{\mathbf{M}})$ 의 값(오른쪽)

Fig. 6. VAF and objective function  $e(\mathbf{M}, \hat{\mathbf{M}})$  values according to number of muscle synergies

로 설정하였으며  $\tau_n$ 의 초기값은  $T_{syn}$ 이  $N_{syn}$ 에 따라 일정한 간격을 갖도록 설정하였다. TI/TV 머슬시너지 최적화는 머슬시너지 개수에 따라 총 10회 진행하였으며, VAF (variance accounted for)와 오차( $e(\mathbf{M}, \hat{\mathbf{M}})$ , error) 값을 각 실험에서 계산한다. VAF의 정의는 아래와 같다.

$$VAF(\mathbf{M}, \hat{\mathbf{M}}) = 1 - \frac{\|\mathbf{M} - \hat{\mathbf{M}}\|_2^2}{\|\mathbf{M}\|_2^2}. \quad (5)$$

실험을 진행한 computational 환경은 다음과 같다. CPU는 i7-13700F(Intel, US)를 사용하였으며, RAM은 32GB이다. MATLAB(Mathwork, US) 프로그램의 fmincon 함수를 사용하였고, 최적화 파라미터를 위한 optimoptions 함수 설정은 아래의 표 1의 값들과 같다.

## 5. 결과 및 토의

### 5.1 머슬시너지 개수에 따른 목적함수 및 VAF 값

그림 6은 머슬시너지의 개수에 따른 VAF 값(왼쪽)과 오차( $e(\mathbf{M}, \hat{\mathbf{M}})$ , error) 값을 보여주고 있다. 그림에서 두 그래프의 가로축은 머슬시너지의 개수  $N_{syn}$ 를 의미하며, 세로축은 각각 VAF 값과 오차값을 의미한다. 빨간색으로 표현된 막대그래프는 TI 머슬시너지의 경우, 파란색으로 표현된 막대그래프는 TV 머슬시너지의 경우를 의미한다. 막대그래프의 값은 10번의 최적화 결과에 대한 평균값을 의미하며, 막대 위의 범위는 표준편

표 1. 최적화 알고리즘을 위한 optimoptions의 파라미터  
Table 1. Parameters of optimoptions function  
for optimization algorithm

Parameter	Value
MaxFunctionEvaluations	inf
MaxIterations	5e+2
OptimalityTolerance	1e-03
StepTolerance	1e-03
HessianApproximation	'lbfgs'
UseParallel	true

차를 의미한다. 두 그래프에서 볼 수 있는 것처럼, 머슬시너지의 개수가 증가함에 따라 VAF 값은 점차 증가하며, 오차값은 감소하는 것을 볼 수 있다. 또한, 전체적으로 TI 머슬시너지 경우가 TV 머슬시너지의 경우보다 VAF 값은 크고 오차값은 낮은 것을 볼 수 있다. 이는 TI의 경우가 TV의 경우보다 sEMG를 최적화하는 데 사용된 변수가 일반적으로 더 많기 때문이다.

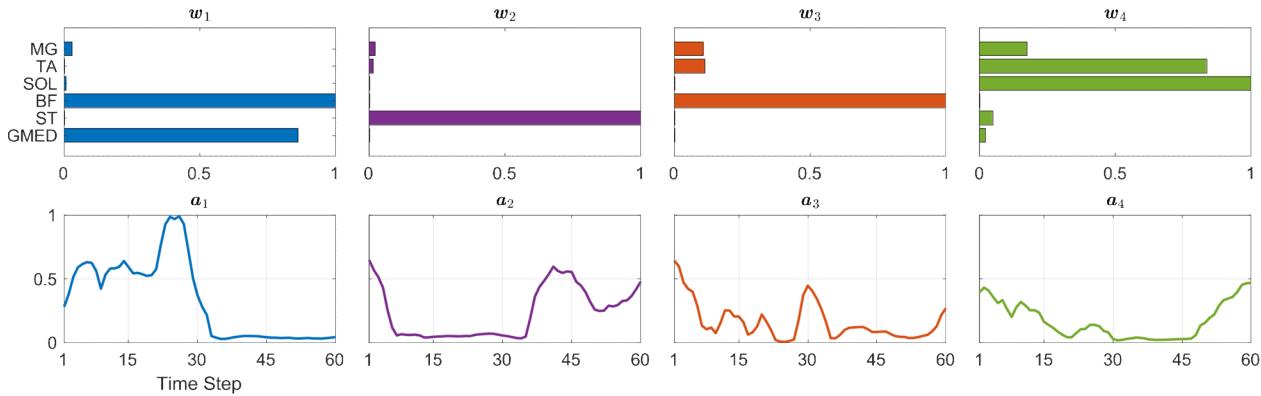
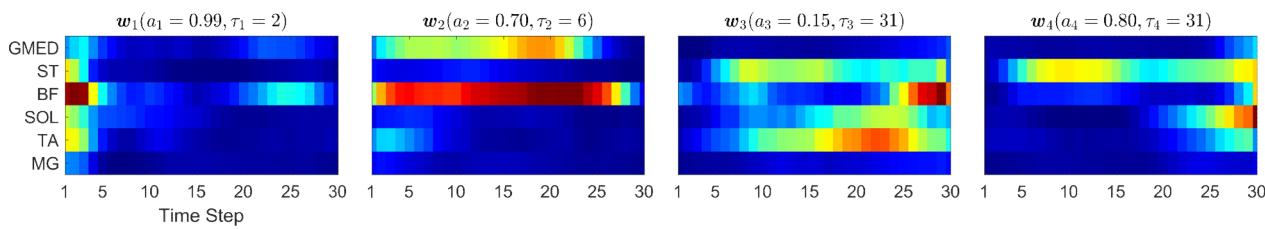
$$N_{syn}(N_{ch} + TN_{data}) > N_{syn}(N_{ch}T_{syn} + 2N_{data}). \quad (6)$$

위 수식에서 왼쪽 항은 TI 머슬시너지 최적화에 필요한 변수의 개수를 말하고, 오른쪽 항은 TV 머슬시너지 최적화에 필요한 변수의 개수를 말한다. TI의 경우  $N_{syn}$  개의  $w_n$  와  $a_n$ 의 요소(element) 개수를 고려해야 하고, TV의 경우  $N_{syn}$  개의  $w_n$ ,  $a_n$  그리고  $\tau_n$ 의 개수를 고려해야 한다. 실험을 통해 설정한 모든  $N_{syn}$ 에 대하여 수식 (5)를 적용할 때, TI 최적화 변수의 개수가 항상 더 많음을 볼 수 있다.

### 5.2 머슬시너지 추출 결과 및 머슬시너지 해석

그림 7은  $N_{syn} = 4$  일 때의 TI 머슬시너지 추출 결과를 보여준다. 그림에서 위 행은 TI 머슬시너지이며, 아래 행은 활성화 커브를 보여준다. 머슬시너지의 가로축은 근육의 활성화 정도를 0~1 사이값으로 나타내며, 세로축은 채널에 해당하는 근육을 의미한다. 활성화 커브에서 가로축은 타임 스텝을 의미하며, 세로축은 머슬시너지의 활성화 정도를 0~1 사이값으로 나타낸다.  $w_1$ 는 대퇴이두근(BF)과 중둔근(GMED)을 사용하기 위한 머슬시너지이며,  $w_2$ 와  $w_3$ 는 각각 반힘줄근(ST)과 대퇴이두근(BF)만으로 구성된 머슬시너지이다.  $w_4$ 는 앞정강근(TA)과 가자미근(SOL)을 주로 사용하는 머슬시너지이다.  $w_1$ 는 보행을 시작할 때 주로 사용되는 머슬시너지이며, 보행의 마지막에는  $w_2$ 와  $w_4$ 가 주로 사용되며,  $w_3$ 은 보행의 중간에서 주로 사용되는 머슬시너지이다. 그림 7의 머슬시너지와 활성화 커브를 사용하여 계산된 오차( $e(\mathbf{M}, \hat{\mathbf{M}})$ )의 값은 0.2478, VAF 값은 0.9943이며, 결과를 통해 최적화가 잘 되었음을 볼 수 있다.

그림 8은  $N_{syn} = 4$  일 때의 TV 머슬시너지 추출 결과를 보여준다. 그림에서 머슬시너지의 가로축은 타임 스텝, 세로축은 각 채널에 해당하는 근육을 의미한다. 머슬시너지 그림에서 0~1 사이의 값을 파란색에서 빨간색 사이 색상으로 표현했다. TV 머슬시너지  $w_n$ 에 상응하는  $a_n$ 와  $\tau_n$ 는 해당 머슬시너지 상단에 표시하였다. 그림에서 볼 수 있는 것처럼  $w_1 \sim w_4$  순서에 따라 머슬시너지가 활성화되는 것을 볼 수 있다.  $w_1$ 의 경우 대퇴이두근(BF)을 주로 사용하고 있으며,  $w_2$ 는 대퇴이두근(BF)에 더하여 중둔근(GMED)을 함께 사용하는 머슬시너지로 볼 수 있다.  $w_3$ 과  $w_4$ 는 같은 지연시간 계수를 갖지만, 각기 다른 근육들을 주로 사용하는 것을 볼 수 있다.  $w_3$ 의 경우 반힘줄근(ST)과 앞정강근(TA)을

그림 7. TI 머슬시너지 추출 결과( $N_{syn} = 4$ )Fig. 7. Extracted TI muscle synergies and activation curves( $N_{syn} = 4$ )그림 8. TV 머슬시너지 추출 결과( $N_{syn} = 4$ )Fig. 8. Extracted TV muscle synergies, activation coefficients, and time delay coefficients( $N_{syn} = 4$ )

먼저 사용하다가 대퇴이두근(BF)를 사용하는 것을 볼 수 있으며,  $w_4$ 의 경우 처음에는 반힘줄근(ST)을 사용하다가 가자미근(SOL)을 사용하는 것을 확인할 수 있다. 그럼 8의 머슬시너지, 활성화 계수, 지연시간 계수로 계산된 오차( $e(\mathbf{M}, \hat{\mathbf{M}})$ )의 값은 4.7335, VAF 값은 0.8737이다. 결과를 통해, TV 머슬시너지 추출 결과가 TI 머슬시너지에 비하여 오차가 크고 VAF가 낮지만, 최적화는 성공적으로 되었음을 볼 수 있다.

## 6. 결 론

본 논문은 TI/TV 머슬시너지 추출을 최적화 문제로 정의하고, 최적화 문제를 수치적으로 풀기 위한 교대 최적화 기법에 대해 논하였다. 먼저, TI/TV 머슬시너지의 개념 및 수학적 정의를 소개하였고, 이를 추출하는 문제를 제약조건이 부과된 최적화 문제로 정의하기 위한 목적함수와 비음수 조건을 보였다. 정의된 최적화 문제(머슬시너지 추출문제)를 수치적으로 풀기 위해 교대 최적화 프레임워크를 사용하였고, 실험에서는 사람의 보행 시 양쪽 다리 근육에서 측정된 sEMG 데이터를 사용하여 머슬시너지를 추출하였다. 결과를 통해, 교대 최적화 기반 방법론으로 TI/TV 머슬시너지를 모두 성공적으로 추출할 수 있음을 확인하였다. 특히, TI 머슬시너지의 경우가 TV 머슬시너지의 경우보다 목적함수(오차)의 값이 더 작고, VAF 값이 더 큰 것을 볼 수 있었다. 또한, 교대 최적화를 통해 획득한 머슬시너지를 사용해 사람의 보행에 대한 운동 해석을 수행할

수 있었다.

향후 연구에서는 머슬시너지를 통해 해석한 사람의 운동 수행에 대한 정보를 human-robot interface(HRI) 제작에 사용할 예정이다. 특히, 머슬시너지를 사용하여 사람이 수행하고 있는 동작을 구분하거나, 머슬시너지를 통해 추정한 사람의 힘의 크기/방향 정보를, 보다 진보된 HRI 구현을 위해 사용할 수 있을 것으로 기대된다[16][17][18].

## Conflict of Interest

저자는 본 논문에 관련된 어떠한 잠재적인 이해상충도 없음을 선언한다.

## References

- [1] N. A. Bernstein, *The Co-ordination and Regulation of Movements*, Oxford, Pergamon, 1967.
- [2] V. CK Cheung, et al., “Plasticity of muscle synergies through fractionation and merging during development and training of human runners,” *Nature communications*, vol. 11, no. 1, pp. 4356, 2020.
- [3] Z. He, Z. Qin, and Y. Koike, “Continuous estimation of finger and wrist joint angles using a muscle synergy based musculoskeletal model,” *Applied Sciences*, vol. 12, no. 8, pp. 3772, 2022.
- [4] D. Lee and S. Seung, “Learning the parts of objects by non-negative matrix factorization,” *Nature*, vol.

- 401, no. 6755, pp. 788–791, 1999.
- [5] J. C. Bezdek and R. J. Hathaway, “Some notes on alternating optimization,” *Proceedings of the 2022 AFSS International Conference of Fuzzy Systems*, Calcutta, India, pp. 288–300, Feb., 2022.
- [6] C Lin, “Projected gradient methods for nonnegative matrix factorization,” *Neural computation*, vol. 19, no. 10, pp. 2756–2779, 2007.
- [7] X. Lin and P. Boutros, “Optimization and expansion of non-negative matrix factorization,” *BMC bioinformatics*, vol. 21, no. 1, pp. 7, 2020.
- [8] Z. Yuan and E. Oja, “Projective nonnegative matrix factorization for image compression and feature extraction,” *Proceedings of The 14th Scandinavian Conference on Image Analysis*, Joensuu, Finland, pp. 333–342, June 2005.
- [9] T. G. Kang, K. Kwon, J. W. Shin, and N. S. Kim, “NMF-based target source separation using deep neural network,” *IEEE Signal Processing Letters*, vol. 22, no. 2, pp. 229–233, 2014.
- [10] A. d' Avella and M. Tresch, “Modularity in the motor system: decomposition of muscle patterns as combinations of time-varying synergies,” *Advances in neural information processing systems*, vol. 14, 2001.
- [11] A. d'Avella and F. Lacquaniti, “Control of reaching movements by muscle synergy combinations,” *Frontiers in computational neuroscience*, vol. 7, pp. 42, 2013.
- [12] H. Park, et al., “Classification of gait phases based on a machine learning approach using muscle synergy,” *Frontiers in Human Neuroscience*, vol. 17, pp. 1201935, 2023.
- [13] K. Kutsuzawa and M. Hayashibe, “Imitation learning with time-varying synergy for compact representation of spatiotemporal structures,” *IEEE Access*, vol 11, pp. 34150–34162, 2023.
- [14] J. Camargo, et al., “A comprehensive, open-source dataset of lower limb biomechanics in multiple conditions of stairs, ramps, and level-ground ambulation and transitions,” *Journal of Biomechanics*, vol. 119, pp. 1–9, 2021.
- [15] H. J. Hermens, et al., “SENIAM European recommendations for surface electromyography: results of the SENIAM project,” *Roessingh Research and Development*, Enschede, Netherlands, 1999.
- [16] G. Torres-Oviedo, J. M. Macpherson, and L. H. Ting, “Muscle synergy organization is robust across a variety of postural perturbations,” *Journal of Neurophysiology*, vol. 96, no. 3, pp. 1530–1546, 2006.
- [17] J. L. McKay and L. H. Ting, “Functional muscle synergies constrain force production during postural tasks,” *Journal of Biomechanics*, vol. 41, no. 2, pp. 299–306, 2008.
- [18] D. J. Berger and A. d'Avella, “Effective force control by muscle synergies,” *Frontiers in Computational Neuroscience*, vol. 8, pp. 46, 2014.

## 저자 소개



김장현 (Janghyeon Kim)

2022년 : 연세대학교 미래캠퍼스  
컴퓨터공학부 공학사

2024년 : 연세대학교 전산학과 과학석사  
2024년 4월~11월 : 한국생산기술연구원  
로봇그룹 연구원

2025년 3월~현재 : 연세대학교  
미래캠퍼스  
뉴로로보틱스연구실  
연구원

관심분야 : 로봇 플래닝/모델링/제어, 시연데이터  
기반 기계학습, 양팔로봇제어및플래닝

ORCID Number : 0000-0002-7327-9706

E-mail : janghyeonk@yonsei.ac.kr



윤한얼(Han Ul Yoon)

2004년/2006년: 중앙대학교  
전자전기공학부 공학사/공학석사

2014년 : 일리노이대학교 어바나-샴페인  
전기컴퓨터공학과 공학박사

2014년~2016년 : 텍사스 A&M 대학교  
Postdoctoral research  
associate

2017 : 텍사스 A&M 대학교  
조교수(강의전담)

2017년 10월~2020년 2월:  
한국생산기술연구원 로봇그룹  
선임연구원

2020년 3월~현재: 연세대학교(미래)  
소프트웨어학부  
부교수

관심분야 : 모방학습, 로봇 플래닝/모델링/제어, 멀티모달리티 센싱기반 강화학습

ORCID Number : 0000-0001-8870-3103

E-mail : huyoon@yonsei.ac.kr